

刘俊豪

地址: 北京大学新燕园校区

电子邮件: liujunhao@pku.edu.cn

主页: <https://outerform.site>

个人简介

我的研究聚焦可解释人工智能 (XAI), 尤其关注面向 LLM 与多模态模型的高效解释方法, 以及基于解释的模型优化与控制。除学术研究外, 我拥有大语言模型与多模态/图像生成模型预训练经验。此外, 长期算法竞赛训练 (NOI 金牌、ICPC/CCPC 金牌) 也为我提供了扎实的算法基础与工程实现能力。

教育背景

- 北京大学 · 计算机学院 · 程序设计语言研究室

博士研究生 | 计算机软件与理论

导师: 张昕

2022.9 – 2027.6 (预计)
- 北京大学 · 信息科学技术学院

学士 | 计算机科学与技术

GPA 排名前 11%, 北京市优秀毕业生

2018.9 – 2022.6
- 重庆市第八中学校

初中及高中

2012.9 – 2018.6

实习经历

- 小红书 · 研究实习生 (Ace「顶尖实习生」计划)

2026.6 – 至今

Dots 团队

北京

◦ 工作内容: 参与大语言模型预训练, 负责代码语料处理与多源数据混合策略设计。
- 腾讯 · 研究实习生 (青云计划)

2025.7 – 2026.5

混元多模态模型团队

北京

◦ 工作内容: 参与混元图像模型 (HunyuanImage) 的研发, 专注于模型可解释性与可控性研究, 探索对模型行为的透理解与精准调控方法。

论文发表

- Liu, Junhao, Haonan Yu, Zhenyu Yan, and Xin Zhang. Revitalizing Black-Box Interpretability: Actionable Interpretability for LLMs via Proxy Models. ACL 2026 主会 (Oral, 4.12%)。

摘要: 大语言模型的模型无关解释因高昂的扰动成本而难以实现。我们提出基于代理模型的解释框架, 通过筛选-应用机制将低成本模型的解释迁移至目标 LLM, 以仅 9.5% 的成本实现 90% 以上的解释保真度, 并在提示压缩和有毒样本移除等下游任务中验证了其有效性。
- Liu, Junhao, Haonan Yu, Zhenyu Yan, and Xin Zhang. Focus-LIME: Surgical Interpretation of Long-Context Large Language Models via Proxy-Based Neighborhood Selection. IJCAI-ECAI 2026。

摘要: 随着 LLM 上下文窗口不断扩大, 在高风险任务中实现精细的特征级解释愈发重要。我们提出 Focus-LIME, 通过代理模型筛选扰动邻域, 使目标模型仅在优化后的上下文内进行细粒度归因, 实验验证了该方法的可行性与忠实性。
- Liu, Junhao, and Xin Zhang. ReX: A framework for incorporating temporal information in model-agnostic local explanation techniques. AAAI 2025 (Oral, 4.68%)。

摘要： 现有模型无关局部解释技术未能考虑时序信息，在处理变长输入模型时效果不佳。我们提出通用框架 ReX，通过改进采样过程与代理特征统一引入时序信息，并在 Anchors、LIME 和 Kernel SHAP 上进行了实例化。实验结果表明，ReX 显著提升了解释保真度，超越了现有模型专用解释技术。

• Li, Tianchi, Zhenyu Yan*, **Junhao Liu***, Peng Di, and Xin Zhang. Guiding LLM-based Loop Invariant Synthesis via Feedback on Local Reasoning Errors. TOPLAS, 2026.

摘要： 我们提出一种新框架，通过形式化验证 LLM 的推理过程来检测局部逻辑错误，并据此提供针对性反馈。将该框架应用于循环不变式合成问题，所实现的工具 LORIS 在 460 个 C 程序上取得了 93.1% 的成功率，并在非线性属性基准上表现出良好的鲁棒性。

• Yu, Haonan, **Junhao Liu**, and Xin Zhang. MAnchors: Memorization-Based Acceleration of Anchors via Rule Reuse and Transformation. ICML 2026.

摘要： Anchors 因计算开销大而难以实际部署。我们提出基于记忆的加速框架，通过缓存与复用历史解释中的中间结果，经横向和纵向转换适配新输入。在表格、文本与图像数据上的实验表明，该方法大幅缩短生成时间，同时保持解释质量。

* 相同贡献

预印本

• **Liu, Junhao**, Jian-Wei Zhang, Tao Huang, Miles Yang, Zhao Zhong, and Liefeng Bo. Think, Plan, Paint: Layout-Aware Reasoning for Controllable Image Generation in Unified Models. (2026)。

摘要： 统一多模态大语言模型在可控图像生成中仍难以遵循复杂空间指令与逻辑约束。我们提出 ATLAS，以布局作为贯穿空间推理、显式物体规划与图像渲染的共享表示，形成“Think, Plan, and Paint”范式。ATLAS 在图像生成基准上取得了统一多模态模型中的领先表现，并通过同一布局接口支持指令引导编辑和多模态定位。

• **Liu, Junhao**, Haonan Yu, and Xin Zhang. ConLUX: Concept-Based Local Unified Explanations. (2024)。

摘要： 现有基于概念的模型无关解释方法局限于归因形式。我们提出通用框架 ConLUX，利用大模型扰动将现有局部解释技术统一扩展为基于概念的解释，支持归因、充分条件和反事实三种形式。在文本、图像与多模态模型上的评估表明，ConLUX 显著提升了解释的保真度与可理解性。

• Yu, Haonan, **Junhao Liu**, Zhenyu Yan, Haoran Lin, and Xin Zhang. WASD: Locating Critical Neurons as Sufficient Conditions for Explaining and Controlling LLM Behavior. (2026)。

摘要： 我们提出 WASD 框架，通过定位 token 生成的充分神经元条件来解释和控制模型行为。该方法将候选条件建模为神经元激活谓词，并迭代搜索保证当前输出的最小集合。实验表明，所得解释比传统归因图更稳定、准确且简洁。

竞赛获奖与在校荣誉

• 竞赛获奖		
ICPC EC-Final 金牌，亚洲区域赛金牌		2018 – 2021
CCPC 总决赛金牌，区域赛金牌		2019 – 2021
NOI 金牌		2017
• 学校奖励		
优秀科研奖		2023
北京市优秀毕业生		2022
国家奖学金、北京大学一等奖学金、北京大学三好学生标兵		2019 – 2021

其他项目经历

- MTML：无数据竞争与死锁的多线程语言

2023.3 – 2023.6

基于 OCaml 开发多线程编程语言 MTML，通过类型系统从根源上避免死锁与数据争用。项目开源于 Github：
<https://github.com/outerform/DPPL-project>。
- 基于用户的协同过滤算法的分布式实现与效率对比

2023.5 – 2023.6

分别使用 Spark 和 Hadoop 实现基于用户的协同过滤算法，并对两者的运行效率进行比较。结果表明 Spark 在整体上表现出更高的执行效率。
- EasyFile：自动化电子文档处理工具

2021.9 – 2021.12

针对 Office 文档、PDF 等处理中的重复性工作，开发自动化工具 EasyFile。项目开源于 GitHub：
<https://github.com/Yibo-He/EasyFile>。
- 基于启发式 EuSolver 的语法制导程序合成器

2021.12 – 2022.1

实现结合 SMT 求解器的语法制导程序合成方法，针对 CLIA 与程序结构设计启发式规则，提升合成效率与效果。
- Java 指针分析器

2021.9 – 2021.11

开发支持流敏感、上下文敏感与域敏感分析的 Java 指针分析工具，用于辅助检测内存相关缺陷。

教学经历（助教）

概率编程导论（研究生课）	2024 春
离散数学导论	2024 秋
程序设计实习	2023 春
计算概论 (B)	2022 秋
数据结构与算法实习	2020 秋

专业技能与兴趣爱好

- 开发能力: 常用 C/C++、Python；熟悉 Linux、Git、Docker 等工具的使用
- 语言能力: 英语六级 628
- 兴趣爱好: 游泳，长跑，模拟赛车